

CRYPTO EXCHANGE v1.0

Pipeline de Análisis de Criptomonedas en Tiempo Real

Memoria Técnica — Proyecto Final · Big Data Aplicado

Alumno	Francisco José Camarasa
Módulo	Big Data Aplicado
Repositorio	github.com/FranOfRip/crypto-exchange
Stack	Kafka · Spark · HDFS · Hive · Prometheus · Grafana · Docker Compose



1. Resumen del Proyecto

Pipeline Big Data completo para el análisis de criptomonedas en tiempo real. Los datos se capturan desde Binance vía WebSocket (sin registro ni API key), se ingestan en Kafka, se procesan con Spark Structured Streaming, se persisten en HDFS en Parquet y se visualizan en Grafana con métricas de Prometheus.

Flujo: Binance WS → Producer Python → Kafka → Spark Streaming → HDFS + Prometheus → Grafana

Componente	Tecnología	Función
Fuente	Binance WebSocket	Stream público ~1 msg/s por par. BTC/USDT y ETH/USDT
Ingesta	Apache Kafka 7.6.0	Bus de eventos con 2 topics: crypto_ticker y crypto_kline
Procesamiento	Spark Structured Streaming	SMA 5min, variación %, volumen, pump & dump
Almacenamiento	HDFS + Hive 3.1.3	Parquet particionado por par y fecha. 3 queries HQL
Observabilidad	Prometheus + Grafana	8 métricas propias, 2 dashboards, 3 alertas
Orquestación	Docker Compose	13 servicios en red crypto_net

2. Arquitectura




Figura 1 — Flujo de datos implementado sobre Docker Compose (red crypto_net)

Servicio	Puerto(s)	RoI
Zookeeper + Kafka	2181 / 9092	Bus de eventos. Topics: crypto_ticker y crypto_kline
Producer Python	8000	WebSocket Binance → Kafka. Métricas en :8000/metrics
Spark Streaming	8001	Procesamiento. Métricas en :8001/metrics
HDFS Namenode + Datanode	9870 / 9864	Filesystem distribuido. UI en :9870
Hive Metastore + HiveServer2	9083 / 10000	Consultas HQL sobre tablas externas Parquet
Prometheus + Grafana	9090 / 3000	Observabilidad. Provisioning automático de dashboards
Node Exporter + cAdvisor	9100 / 8082	Métricas del host y de cada contenedor Docker

☐	crypto-exchange	-	-	-	924.24%	5.13GB / 91.54Gi	67.23%	233.45MB / 2.99i	273.5i	5, 20, 89, 17, 72, 1	58 minutes ago				
☐	namenode	4c462106cdaa	bde2020/hadoop	9000-9000 Show all ports (2)	186.18%	493.2MB / 7.63G	6.31%	22.6MB / 92.4ME	10.4M	89	58 minutes ago				
☐	hiveserver	eb341170a6ad	apache/hive:3.1	10000-10000 Show all ports (2)	2.12%	664MB / 7.63GB	8.5%	50.1MB / 62.9ME	1.88Ki	45	58 minutes ago				
☐	hive-metastore	0e3d5b3cbfe	apache/hive:3.1	9083-9083 Show all ports (2)	0.11%	435.9MB / 7.63G	5.58%	16MB / 18.2MB	1.96Ki	30	58 minutes ago				
☐	datanode	12725114aa65	bde2020/hadoop	9864-9864 Show all ports (2)	2.06%	369.9MB / 7.63G	4.74%	12.3MB / 50.8ME	24.9M	89	58 minutes ago				
☐	zookeeper-1	4ade5657c24e	confluentinc/cp-	2181-2181 Show all ports (2)	0.19%	120.3MB / 7.63G	1.54%	11.7MB / 1.81ME	103KE	72	58 minutes ago				
☐	spark-1	f9a7b1c09e75	crypto-exchange	8001-8001 Show all ports (2)	726.7%	2.14GB / 7.63GB	28%	42.6MB / 2.63GB	109Mi	332	58 minutes ago				
☐	prometheus-1	7fd8df05642f	prom/prometheus	9090-9090 Show all ports (2)	0%	293.1MB / 7.63G	3.75%	8.16MB / 12.2ME	86.6M	17	58 minutes ago				
☐	producer-1	c410f26fc3db	crypto-exchange	8000-8000 Show all ports (2)	0.68%	25.43MB / 7.63G	0.33%	16.8MB / 147KB	5.32M	4	58 minutes ago				
☐	node-exporter	920971d37110	prom/node-exporter	9100-9100 Show all ports (2)	0%	15.91MB / 7.63G	0.2%	11.7MB / 0B	167KE	5	58 minutes ago				
☐	kafka-1	38b725bac05e	confluentinc/cp-	9092-9092 Show all ports (2)	1.34%	421.4MB / 7.63G	5.39%	14.2MB / 22.2ME	10.4M	87	58 minutes ago				
☐	grafana-1	d2c2efb23f75	grafana/grafana	3000-3000 Show all ports (2)	0.6%	111MB / 7.63GB	1.42%	20.7MB / 111MB	25.4M	19	58 minutes ago				
☐	cadvisor-1	3ec257b2c88e	cadvisor/cadvisor	8082-8080 Show all ports (2)	4.26%	114.8MB / 7.63G	1.47%	6.59MB / 0B	1.21M	20	58 minutes ago				

3. Decisiones de Diseño

3.1 Fuente de datos — Binance WebSocket

Se monitorizan BTC/USDT y ETH/USDT con dos streams por par: @miniTicker (precio, volumen, ~1 msg/s) y @kline_1m (velas OHLCV). Se descartan @trade y @depth porque emiten una operación por evento y saturarían el broker Kafka local.

Reconexión automática: bucle while True que relanza el WebSocket ante cualquier desconexión (delay 5s). El producer reintenta la conexión a Kafka hasta 15 veces al arrancar.

Normalización: funciones dedicadas (normalizar_miniticker y normalizar_kline) convierten el formato de Binance al esquema interno del pipeline antes de publicar en Kafka.

3.2 Kafka — Diseño de topics

Se usan 2 topics separados por tipo de dato. Un topic único obligaría a Spark a filtrar por tipo en cada micro-batch. Topics por par escalarían mal (con 10 pares serían 20 topics).

- crypto_ticker — mensajes @miniTicker: precio, volumen, timestamps. Consumido por Spark.
- crypto_kline — velas @kline_1m: OHLCV, número de trades, flag vela cerrada. Producido pero pendiente de consumer en Spark.

Retención: 24h y máximo 1 GB. Suficiente para reprocesar el día si el consumer cae. 1 broker con replication_factor=1, coherente con un entorno de desarrollo de un solo nodo.

3.3 HDFS — Parquet y particionado

Criterio	CSV / JSON	Parquet (elegido)
Compresión	Básica o nula	Columnar: hasta 80% menos espacio en series temporales
Lectura	Todas las columnas	Column pruning + predicate pushdown
Esquema	Implícito, frágil	Embebido y validado automáticamente por Spark/Hive

Particionado por y fecha: /data/crypto/par=BTCUSDT/fecha=2025-06-07/part-00000.parquet. Permite a Hive descartar particiones sin leerlas. Solo por fecha mezclaría pares; solo por par haría lentas las consultas temporales.

Replicación = 1: con un único DataNode, replicación 3 causaría estado under-replicated permanente y HDFS entraría en safe mode bloqueando escrituras.

rw-r--r--	3	root	supergroup	3343	2026-06-07	09:51	/data/crypto/par=BTUSD/fecha=2026-06-07/part-00000-00a3d0d0-0a4c-42ca-997a-28a20e2c240c.c000.snappy.parquet
rw-r--r--	3	root	supergroup	3288	2026-06-07	10:21	/data/crypto/par=BTUSD/fecha=2026-06-07/part-00000-071a54f-b8fa-4e63-9acc-89f85f09f6a5.c000.snappy.parquet
rw-r--r--	3	root	supergroup	3352	2026-06-07	10:25	/data/crypto/par=BTUSD/fecha=2026-06-07/part-00000-073e5b24-ca7f-4af6-8ac5-9a8f38b31711.c000.snappy.parquet
rw-r--r--	3	root	supergroup	3356	2026-06-07	10:39	/data/crypto/par=BTUSD/fecha=2026-06-07/part-00000-07940e60-a044-45ce-910f-a80e3c80e409.c000.snappy.parquet
rw-r--r--	3	root	supergroup	3398	2026-06-07	10:11	/data/crypto/par=BTUSD/fecha=2026-06-07/part-00000-07faa183-2f52-4480-a706-226a75b94d48.c000.snappy.parquet
rw-r--r--	3	root	supergroup	3270	2026-06-07	09:48	/data/crypto/par=BTUSD/fecha=2026-06-07/part-00000-082691f7-2ad8-4cb0-85c1-9b3f0fba51cd.c000.snappy.parquet
rw-r--r--	3	root	supergroup	3136	2026-06-07	10:23	/data/crypto/par=BTUSD/fecha=2026-06-07/part-00000-0880e58b-d3fc-4de9-9172-7d7129b1e682.c000.snappy.parquet
rw-r--r--	3	root	supergroup	3334	2026-06-07	10:51	/data/crypto/par=BTUSD/fecha=2026-06-07/part-00000-08873586-3e29-481f-8875-71d53bd44869.c000.snappy.parquet
rw-r--r--	3	root	supergroup	3186	2026-06-07	09:43	/data/crypto/par=BTUSD/fecha=2026-06-07/part-00000-08f7559e-cff8-4633-938c-e7aae259d7c1.c000.snappy.parquet
rw-r--r--	3	root	supergroup	3219	2026-06-07	10:21	/data/crypto/par=BTUSD/fecha=2026-06-07/part-00000-0974f046-72e6-442a-92af-b158f76a1a88.c000.snappy.parquet
rw-r--r--	3	root	supergroup	3289	2026-06-07	10:19	/data/crypto/par=BTUSD/fecha=2026-06-07/part-00000-097a8106-733b-47ad-9100-e81d5d9c5200.c000.snappy.parquet
rw-r--r--	3	root	supergroup	3324	2026-06-07	10:22	/data/crypto/par=BTUSD/fecha=2026-06-07/part-00000-098f24c8-c96b-4365-8bda-c920e427bb4f.c000.snappy.parquet
rw-r--r--	3	root	supergroup	3289	2026-06-07	09:55	/data/crypto/par=BTUSD/fecha=2026-06-07/part-00000-0a942383-56d3-4f7e-8753-3013b6357dbc.c000.snappy.parquet
rw-r--r--	3	root	supergroup	3207	2026-06-07	10:26	/data/crypto/par=BTUSD/fecha=2026-06-07/part-00000-0aa49118-31e9-4166-961a-9824dc610581.c000.snappy.parquet
rw-r--r--	3	root	supergroup	3398	2026-06-07	10:36	/data/crypto/par=BTUSD/fecha=2026-06-07/part-00000-0acc91f0-11eb-44d8-a682-c09f4256ba6b.c000.snappy.parquet
rw-r--r--	3	root	supergroup	3333	2026-06-07	10:14	/data/crypto/par=BTUSD/fecha=2026-06-07/part-00000-0ad23175-d652-4a67-a163-b4a616ef8f02.c000.snappy.parquet
rw-r--r--	3	root	supergroup	3247	2026-06-07	10:27	/data/crypto/par=BTUSD/fecha=2026-06-07/part-00000-0bb1d605-22c5-45b3-9763-02119bdc2540.c000.snappy.parquet
rw-r--r--	3	root	supergroup	3380	2026-06-07	10:01	/data/crypto/par=BTUSD/fecha=2026-06-07/part-00000-0bca4fdb-19ca-46c2-ac82-91ee341c2476.c000.snappy.parquet
rw-r--r--	3	root	supergroup	3236	2026-06-07	10:25	/data/crypto/par=BTUSD/fecha=2026-06-07/part-00000-0bfb6e3d-88f2-43d1-b646-83004009cf06.c000.snappy.parquet
rw-r--r--	3	root	supergroup	3314	2026-06-07	10:35	/data/crypto/par=BTUSD/fecha=2026-06-07/part-00000-0c2cf35b-d004-4e50-9620-d2071ae28da9.c000.snappy.parquet
rw-r--r--	3	root	supergroup	3365	2026-06-07	10:15	/data/crypto/par=BTUSD/fecha=2026-06-07/part-00000-0c74a0c2-708b-4b11-9946-ecaaf913acbc.c000.snappy.parquet
rw-r--r--	3	root	supergroup	3379	2026-06-07	09:50	/data/crypto/par=BTUSD/fecha=2026-06-07/part-00000-0c99147f-5dbd-49b0-9dc3-fd06ff320448.c000.snappy.parquet

3.4 Spark Structured Streaming — Ventanas e indicadores

Indicador	Cálculo	Ventana / Slide	Justificación
SMA 5 min	avg(precio_actual)	5 min / 30s	Vela estándar en análisis técnico. Ni ruidosa ni lenta.
Variación %	(máx - mín) / mín × 100	5 min / 30s	Misma ventana que SMA para coherencia.
Volumen medio	avg(volumen_base)	5 min / 30s	Complementa el análisis de precio con liquidez.
Pump & dump	variacion_pct > 2% → flag=1	5 min / 30s	2% filtra ruido normal. Flag inmediato al superar umbral.

Sliding window (slide < duración): las ventanas se solapan. Con slide 30s el indicador se recalcula 2 veces por minuto usando siempre los últimos 5 min de datos, más reactivo que una tumbling window que esperaría 5 minutos.


Watermark 2 minutos: tolera mensajes retrasados sin descartarlos. Protege ante reconexiones del WebSocket donde llegan mensajes desfasados.


3.5 Prometheus y Grafana

Métrica	Tipo	Origen	Qué detecta
binance_mensajes_total{tipo,par}	Counter	Producer	Caída del WebSocket. rate=0 durante 2 min → alerta crítica
kafka_mensajes_publicados_total{topic,par}	Counter	Producer	Pérdida de mensajes hacia Kafka
crypto_precio_actual{par}	Gauge	Producer	Precio tick a tick. Base del panel de negocio en Grafana
spark_sma_5min{par}	Gauge	Spark	Media móvil. Suaviza volatilidad tick a tick
spark_variacion_pct{par}	Gauge	Spark	Volatilidad en ventana. Entrada del detector pump & dump
spark_pump_dump_detectados_total{par}	Counter	Spark	Anomalías acumuladas. Trigger alerta PumpDumpDetectado
spark_volumen_medio{par}	Gauge	Spark	Liquidez del mercado en la ventana
spark_mensajes_procesados_total	Counter	Spark	Throughput del pipeline. Detecta Spark bloqueado

Alerta	Condición	Duración	Severidad	Razón del umbral
ProducerSinMensajes	rate(binance_mensajes_total[2m]) == 0	2 min	Critical	2 min evita falsas alarmas por reconexiones normales (<10s)
PumpDumpDetectado	increase(spark_pump_dump_detectados_total[5m]) > 0	Inmediata	Warning	Cualquier anomalía detectada es relevante
ContenedorMemoriaAlta	container_memory_usage_bytes > umbral	3 min	Warning	Picos breves son normales al arrancar Spark

2 dashboards separados: Infraestructura (CPU, RAM, red por contenedor vía Node Exporter + cAdvisor) y Negocio (precio, SMA, variación, pump & dump, volumen vía métricas propias). Provisioning automático al arrancar Grafana.





El "No data" que me da es porque no ha habido ninguna variación superior al 2% en ventana de 5 minutos durante el periodo de captura

4. Consultas HQL

Tabla externa sobre ficheros Parquet en HDFS. Al ser externa, eliminar la tabla no borra los datos.

```
CREATE EXTERNAL TABLE IF NOT EXISTS crypto_prices (
  tipo STRING, event_time BIGINT, precio_actual DOUBLE,
  precio_apertura DOUBLE, precio_maximo DOUBLE, precio_minimo DOUBLE,
  volumen_base DOUBLE, volumen_quote DOUBLE,
  ingestion_ts BIGINT, event_timestamp TIMESTAMP
) PARTITIONED BY (par STRING, fecha STRING)
STORED AS PARQUET LOCATION 'hdfs://namenode:9000/data/crypto';
MSCK REPAIR TABLE crypto_prices;
```

Query 1 — Resumen diario: precio medio, máximo, mínimo, volumen y ticks por par y día.

```
SELECT par, fecha, AVG(precio_actual) AS precio_medio,
  MAX(precio_actual) AS maximo, MIN(precio_actual) AS minimo,
  AVG(volumen_base) AS volumen_medio, COUNT(*) AS num_ticks
FROM crypto_prices GROUP BY par, fecha ORDER BY fecha DESC, par;
```

Query 2 — Días volátiles: detecta días con variación máx/mín > 1%.

```
SELECT par, fecha,
       ROUND(((MAX(precio_actual)-MIN(precio_actual))/MIN(precio_actual))*100,4)
AS variacion_pct
FROM crypto_prices GROUP BY par, fecha
HAVING variacion_pct > 1 ORDER BY variacion_pct DESC;
```

Query 3 — Correlación BTC/ETH: ratio ETH/BTC diario para detectar movimientos correlados o independientes.

```
SELECT btc.fecha, btc.precio_medio AS btc, eth.precio_medio AS eth,
       ROUND((eth.precio_medio/btc.precio_medio)*100,4) AS ratio_eth_btc
FROM (SELECT fecha, AVG(precio_actual) AS precio_medio FROM crypto_prices
      WHERE par='BTCUSD' GROUP BY fecha) btc
JOIN (SELECT fecha, AVG(precio_actual) AS precio_medio FROM crypto_prices
      WHERE par='ETHUSD' GROUP BY fecha) eth ON btc.fecha=eth.fecha
ORDER BY btc.fecha DESC;
```

```
--
INFO : Completed executing command(queryId=hive_20260607110955_2871a045-bb85-4735-a8eb-55fe
f318f3d9); Time taken: 72.291 seconds
INFO : OK
INFO : Concurrency mode is disabled, not creating a lock manager
+-----+-----+-----+-----+
| par   | fecha   | precio_medio | num_ticks |
+-----+-----+-----+-----+
| BTCUSD | 2026-06-07 | 62441.80187007481 | 5203 |
| ETHUSD | 2026-06-07 | 1630.2479419216522 | 5131 |
+-----+-----+-----+-----+
2 rows selected (80.397 seconds)
0: jdbc:hive2://localhost:10000> 
```

5. Limitaciones y Mejoras

Limitación	Impacto	Mejora futura
crypto_kline no consumido por Spark	Velas OHLCV producidas pero no procesadas ni persistidas	Añadir segundo readStream sobre crypto_kline
1 DataNode / 1 broker Kafka	Sin redundancia. Un fallo detiene el pipeline	3 DataNodes + 3 brokers en producción
Derby como metastore Hive	Solo 1 conexión concurrente a Beeline	PostgreSQL o MySQL como metastore externo
Umbral pump & dump fijo al 2%	Posibles falsos positivos en pares poco líquidos	Umbral dinámico: media ± 2 desviaciones estándar
Sin RSI ni Bollinger Bands	Indicadores técnicos de nivel medio no implementados	RSI 14 periodos via foreachBatch + Window functions
Sin ampliaciones (CoinGecko / Fear&Greed)	Sin contexto de mercado global ni sentimiento	Producers REST con polling 60s / 1h respectivamente

6. Despliegue

Requisitos y arranque

- Docker Desktop con mínimo 8 GB de RAM. Puertos libres: 2181, 3000, 9000, 9083, 9090, 9092, 9870, 10000 git clone <https://github.com/FranOfRip/crypto-exchange.git> && cd crypto-exchange
- docker compose up -d
- Si hay errores docker compose down -v y luego un docker compose up -d
- Esperar 2-3 minutos tras el arranque.

Accesos y verificación

Servicio	URL / Comando
Grafana	http://localhost:3000 (admin / 1234)
Prometheus	http://localhost:9090
HDFS Web UI	http://localhost:9870
cAdvisor	http://localhost:8082
Hive Beeline	docker exec -it hiveserver beeline -u jdbc:hive2://localhost:10000
Datos en HDFS	docker exec namenode hdfs dfs -ls /data/crypto
Logs en vivo	docker compose logs -f producer spark